

Universidade Federal do Rio Grande do Norte

Escola Agrícola de Jundiaí

Análise e Desenvolvimento de Sistemas

TAD0022 - Estatística Aplicada - 2026.1

III Unidade – Apresentação de relatório até dia 29 de junho (Atividade individual)

Este trabalho consiste na análise de dados de uma base de dados do seu interesse. Para isso, visite o site da Kaggle (<https://www.kaggle.com/datasets>) e pesquise uma base de dados do seu interesse que atenda aos seguintes requisitos:

- A base deve ter ao menos 100 amostras (linhas) e 10 variáveis (colunas);
- Ao menos 3 variáveis quantitativas;
- Ao menos 3 variáveis qualitativas.

PARA GUIAR O DESENVOLVIMENTO:

1. Apresente o domínio de aplicação dos dados: cenário e propósito da base dados; descrição das variáveis, incluindo o tipo, escala de mensuração e unidade de medida; quantidade de instâncias e variáveis; e a referência para a base de dados.
2. Efetue uma verificação (Crítica) nos dados: verifique se os valores estão formatados, por exemplo, variáveis quantitativas estão representadas como números com separadores decimais adequados, as variáveis qualitativas estão representadas corretamente, os valores presentes para as variáveis qualitativas são realmente as descritas nas informações da base de dados; existem erros de digitação, etc.; também efetue o tratamento dos valores faltosos pela média, moda, etc.; relate eventuais transformações nas variáveis.
3. Analise a distribuições das variáveis: apresente as estatísticas descritivas adequadas para cada variável (média, moda, mediana, mínimo, máximo, variância, etc.); apresente histogramas, gráficos Q-Q, tabelas de frequência e box-plots para cada variável quando aplicável e interprete cada um; também investigue a presença de valores atípicos e se as variáveis seguem uma distribuição normal.
4. Avalie a correlação entre as variáveis quantitativas, justificando o uso da correlação de Pearson ou Spearman considerando a análise da distribuição das variáveis efetuada no passo anterior;
5. Escolha três variáveis qualitativas importantes para a base de dados. Elabore e teste 3 hipóteses considerando as divisões formadas pelos valores dessas variáveis, (por exemplo, em uma base que possui o valor sexo e renda, avalie se existe diferença entre

as rendas dos homens e mulheres). Apresente as hipóteses nula e alternativa, os resultados e a interpretação (valor-p, nível de significância, conclusão).

6. Compare as médias de tres das variáveis (com mesma variância) e verifique se há igualdade estatística (ANOVA);

7. Escolha uma variável resposta e desenvolva um modelo de regressão. Verifique os pressupostos do modelo e interprete os coeficientes. Avalie a qualidade do ajuste.

PARA GUIAR A PARTE PRÁTICA, DO DESENVOLVIMENTO, SIGA OS SEGUINTE PASSOS:

Neste trabalho, você deverá analisar uma base de dados utilizando técnicas de Estatística Descritiva e Inferencial. O objetivo é compreender os dados, identificar padrões e responder perguntas por meio de testes estatísticos.

Etapa 1 – Conhecendo a base de dados

Antes de iniciar qualquer análise, é importante entender o contexto da base de dados.

Descreva:

- Qual é área da base de dados (saúde, educação, vendas, tecnologia, esportes etc.);
- Qual é o objetivo da coleta dos dados;
- Quantas observações (linhas) e quantas variáveis (colunas) existem na base;
- Para cada variável, informe:
 - nome;
 - descrição;
 - tipo (qualitativa ou quantitativa);
 - escala de mensuração (nominal, ordinal, intervalo ou razão);
 - unidade de medida, quando aplicável;
- Informe a fonte ou referência da base de dados.

Ao final desta etapa, o leitor deve compreender claramente o que representam os dados analisados.

Etapa 2 – Inspeção e preparação dos dados

Antes de realizar as análises estatísticas, verifique a qualidade dos dados.

Analise os seguintes aspectos:

- Existem valores ausentes (missing values)?

- Há erros de digitação ou registros inconsistentes?
- As variáveis numéricas estão armazenadas corretamente como números?
- As variáveis categóricas possuem apenas as categorias esperadas?
- Existem valores duplicados?

Caso encontre problemas, realize o **tratamento** adequado, por exemplo:

- substituir valores ausentes pela média, mediana ou moda;
- corrigir erros de digitação;
- padronizar categorias;
- remover registros inválidos, quando necessário.

Descreva todas as modificações realizadas na base de dados e justifique cada decisão.

Etapla 3 – Análise exploratória dos dados

Nesta etapa, explore o comportamento de cada variável.

Para as variáveis quantitativas, apresente, quando aplicável:

- média;
- mediana;
- moda;
- mínimo;
- máximo;
- amplitude;
- variância;
- desvio-padrão;
- quartis.

Além disso, construa e interprete os seguintes gráficos:

- histograma;
- boxplot;
- gráfico Q-Q (QQ Plot).

Para as variáveis qualitativas, apresente:

- tabela de frequências;
- gráfico de barras ou setores.

Durante a análise, responda às seguintes perguntas:

- Existem valores atípicos (outliers)?
- A distribuição dos dados é aproximadamente normal?
- Quais características chamam mais atenção em cada variável?

Etapla 4 – Correlação entre variáveis

Escolha as principais variáveis quantitativas da base e analise a relação entre elas.

Para isso:

- calcule a matriz de correlação;
- escolha o método adequado:
 - Correlação de Pearson (quando os dados apresentarem distribuição aproximadamente normal);
 - Correlação de Spearman (quando essa condição não for atendida).

Apresente:

- a matriz de correlação;
- a interpretação da intensidade e direção das correlações;
- a justificativa da escolha do método utilizado.

Etapla 5 – Testes de hipóteses

Selecione **três variáveis qualitativas** relevantes para a base de dados.

Para cada uma delas:

1. Formule uma pergunta de pesquisa.

Exemplo:

A renda média é diferente entre homens e mulheres?

2. Escreva as hipóteses:
 - Hipótese nula (H_0);
 - Hipótese alternativa (H_1).
3. Escolha o teste estatístico adequado.
4. Apresente:
 - nível de significância ($\alpha = 5\%$);
 - valor-p;
 - decisão sobre H_0 ;

- interpretação do resultado em linguagem clara.

Repita esse procedimento para três situações diferentes.

Etapla 6 – Comparação entre médias (ANOVA)

Escolha uma variável qualitativa com **três ou mais grupos** (por exemplo, curso, setor, cidade ou categoria).

Selecione uma variável quantitativa e verifique se existe diferença significativa entre as médias dos grupos utilizando a **Análise de Variância (ANOVA)**.

Apresente:

- hipótese nula; Ex. de H_0 : As médias do grupo 1 é igual a média do grupo 2
- hipótese alternativa; Ex. de H_1 : As médias entre os grupos são diferentes
- resultado da ANOVA;
- valor-p;
- conclusão.

Caso exista diferença significativa entre os grupos, realize um teste pós-hoc (como o teste de Tukey) para identificar quais grupos diferem entre si.

Etapla 7 – Modelo de regressão

Escolha uma variável quantitativa como variável resposta (dependente).

Em seguida:

- selecione uma ou mais variáveis explicativas;
- ajuste um modelo de regressão linear;
- apresente a equação obtida.

Avalie a qualidade do modelo verificando:

- coeficiente de determinação (R^2);
- significância dos coeficientes;
- análise dos resíduos;
- normalidade dos resíduos;
- homocedasticidade.

Interprete os coeficientes obtidos, explicando o significado de cada variável no modelo.

Ao final, responda:

O modelo é adequado para explicar ou prever a variável resposta? Justifique sua resposta com base nos resultados obtidos.

Entrega

O relatório deverá conter:

- Introdução;
- Descrição da base de dados;
- Metodologia utilizada;
- Resultados de cada etapa;
- Gráficos e tabelas devidamente identificados;
- Interpretação dos resultados (não apenas a apresentação dos valores);
- Conclusão, destacando os principais achados da análise.